

Caracterização e Separação de Variedades de Vinho

1st David Baima Monte

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
davidbmonte@alu.ufc.br

2nd Diego Mendes de Freitas

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
mendesdiego@alu.ufc.br

3rd Gustavo Moraes Teles

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
gustavvomt@gmail.com

4th Rafael Martins Guimarães Vieira

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
rafamgv004@gmail.com

Resumo—Este trabalho apresenta uma investigação exploratória detalhada sobre o conjunto de dados físico-químicos de vinhos tintos e brancos da região do Vinho Verde em Portugal. A análise abrange a caracterização estatística monovariada incondicional e condicional às classes, a avaliação bivariada de correlações e a redução de dimensionalidade por Análise de Componentes Principais (PCA) implementada a partir de primeiros princípios. Os resultados demonstram que variáveis como dióxido de enxofre total, acidez volátil e cloretos exibem elevado poder discriminativo individual entre os tipos de vinho. A projeção bidimensional nos dois primeiros componentes principais acumula 50,22% da variância total do sistema e evidencia uma fronteira de separação predominantemente linear entre as classes, apresentando sobreposição marginal circunscrita a amostras com perfis analíticos intermediários.

Index Terms—Análise exploratória de dados, Análise de Componentes Principais, Vinho Verde, Separação de classes, Estatística descritiva.

I. INTRODUÇÃO

O controle de qualidade na indústria vinícola baseia-se tradicionalmente em avaliações sensoriais realizadas por degustadores especialistas e em testes físico-químicos laboratoriais. A caracterização objetiva de compostos químicos presentes no vinho é fundamental para garantir a padronização do produto, identificar adulterações e compreender as especificidades de diferentes processos de vinificação. No contexto do aprendizado de máquina e da inteligência computacional aplicada, os atributos físico-químicos atuam como variáveis preditoras para tarefas de classificação e regressão.

Antes da aplicação de modelos preditivos complexos, a análise exploratória de dados (EDA) constitui uma etapa indispensável no fluxo de trabalho analítico. A EDA permite identificar a distribuição amostral, detectar a presença de valores discrepantes (*outliers*), avaliar dependências lineares entre variáveis e determinar quais atributos possuem poder discriminativo individual ou conjunto para a separação de classes.

Neste artigo, analisa-se o conjunto de dados de vinho (*Wine Quality Dataset*), composto por amostras das variantes

encarnada (vinho tinto) e branca (vinho branco). Desenvolve-se uma abordagem metodológica estruturada em três eixos: (i) caracterização estatística monovariada incondicional e condicional; (ii) análise bivariada e cálculo da matriz de correlação de Pearson; e (iii) implementação customizada da Análise de Componentes Principais (PCA) sem o auxílio de bibliotecas prontas de decomposição. O objetivo central consiste em determinar o grau de separabilidade entre os tipos de vinho a partir de suas propriedades químicas e discutir as implicações físico-químicas dos resultados obtidos.

II. METODOLOGIA E BASE DE DADOS

A. Descrição do Conjunto de Dados

A base selecionada corresponde à Alternativa Três da especificação do trabalho prático. O conjunto foi unificado a partir de dois arquivos distintos referentes às duas colorações de vinhos, adotando-se o tipo do vinho como o rótulo da classe alvo para uma tarefa de classificação binária.

A base consolidada possui as seguintes características globais:

- Número total de observações N igual a 6497.
- Número de preditores D igual a 12 (doze).
- Número de classes L igual a 2 (duas).

A distribuição das classes é assimétrica. A classe correspondente ao vinho branco domina o conjunto com 4898 amostras, o que representa aproximadamente setenta e cinco por cento dos dados globais. O vinho tinto compõe o restante com 1599 registros únicos.

B. Processos de Análise Monovariada

A etapa incondicional avaliou todos os doze atributos simultaneamente, sem distinção de rótulos. Calculou-se a média, o desvio padrão e o grau de assimetria espacial para evidenciar o comportamento padrão das variáveis. A visualização ocorreu por meio de histogramas e diagramas de caixa.

A fase condicional filtrou os registros para cada uma das duas classes separadamente. Isso permitiu quantificar as mesmas métricas estatísticas e gerar gráficos comparativos

individuais, evidenciando as distinções numéricas exatas entre as bebidas.

C. Processos de Análise Bivariada e Multivariada

Para investigar a interação mútua entre os preditores, geramos gráficos de dispersão em pares e uma matriz de correlação. A força das relações lineares foi quantificada e rigorosamente discutida.

Como etapa final, aplicou-se a técnica de Análise de Componentes Principais implementada diretamente da base algébrica. A matriz de covariância foi decomposta em seus autovalores e autovetores associados. Os dados, previamente normalizados, foram projetados nos dois componentes principais dominantes para fins de visualização no plano.

III. RESULTADOS INCONDICIONAIS

Os números extraídos de todo o arranjo de dados revelam que uma vasta porção dos atributos contínuos apresenta distribuições consideravelmente assimétricas. O nível de concentração de cloretos, por exemplo, demonstrou uma distorção positiva muito elevada, de valor cinco inteiros e trinta e nove centésimos, indicando a presença constante de muitos valores discrepantes habitando a cauda direita do plano cartesiano.

O teor alcoólico médio aferido em toda a base consolidada situou-se em torno de dez inteiros e quarenta e nove centésimos, abrigando um desvio padrão estreito de um inteiro e dezenove centésimos. A acidez volátil e o ácido cítrico, componentes cruciais para a estabilidade orgânica do líquido, mantiveram médias baixas, porém com coeficientes de variação moderados, sinalizando grande diversidade nas amostras de engarrafamento.

A documentação disposta na Tabela I sumariza as métricas extraídas em ponto flutuante utilizando a totalidade das observações não categorizadas disponíveis no escopo do estudo.

Tabela I
ESTATÍSTICAS INCONDICIONAIS GLOBAIS

Preditor	Média	Desvio Padrão	Assimetria
fixed acidity	7.215	1.296	1.723
volatile acidity	0.340	0.165	1.495
citric acid	0.319	0.145	0.472
residual sugar	5.443	4.758	1.435
chlorides	0.056	0.035	5.399
free sulfur dioxide	30.525	17.749	1.220
total sulfur dioxide	115.745	56.522	0.001
density	0.995	0.003	0.503
pH	3.218	0.161	0.387
sulphates	0.531	0.149	1.797
alcohol	10.492	1.193	0.566
quality	5.818	0.873	0.190




Figura 1. Histogramas dos preditores - vinho tinto




Figura 2. Histogramas dos preditores - vinho branco




Figura 3. Boxplot Incondicional - Vinho Tinto




Figura 4. Boxplot incondicional - Vinho Branco

IV. RESULTADOS CONDICIONAIS

A média da concentração de dióxido de enxofre livre identificada exclusivamente no vinho branco mostrou ser supe-

rior, excedendo o dobro da concentração observada no vinho tinto. O dióxido de enxofre atua historicamente como um conservante antioxidante vital para vinhos brancos, que possuem estrutura orgânica mais frágil ao contato com oxigênio, justificando perfeitamente a diferença.

De forma simétrica e complementar, o dióxido de enxofre total documentou uma discrepância ainda mais pronunciada entre as subpopulações. O registro alcançou média de cento e trinta e oito inteiros nos brancos, contra ínfimos quarenta e seis inteiros nos exemplares de coloração escura. Em contrapartida química, os vinhos tintos ostentam índices substancialmente mais robustos nas medições de acidez volátil e nos níveis de cloretos.

Tabela II
ESTATÍSTICAS CONDICIONAIS POR CLASSE - VINHO TINTO

Preditor	Média Tinto	Desvio Tinto	Assimetria Tinto
fixed acidity	8.320	1.741	0.982
volatile acidity	0.528	0.179	0.671
citric acid	0.271	0.195	0.318
residual sugar	2.539	1.410	4.536
chlorides	0.087	0.047	5.675
free sulfur dioxide	15.875	10.460	1.249
total sulfur dioxide	46.468	32.895	1.514
density	0.997	0.002	0.071
pH	3.311	0.154	0.194
sulphates	0.658	0.170	2.426
alcohol	10.423	1.066	0.860
quality	5.636	0.808	0.218

Tabela III
ESTATÍSTICAS CONDICIONAIS POR CLASSE - VINHO BRANCO

Preditor	Média Branco	Desvio Branco	Assimetria Branco
fixed acidity	6.855	0.844	0.648
volatile acidity	0.278	0.101	1.577
citric acid	0.334	0.121	1.282
residual sugar	6.391	5.072	1.077
chlorides	0.046	0.022	5.022
free sulfur dioxide	35.308	17.007	1.406
total sulfur dioxide	138.361	42.498	0.391
density	0.994	0.003	0.977
pH	3.188	0.151	0.458
sulphates	0.490	0.114	0.977
alcohol	10.514	1.231	0.487
quality	5.878	0.886	0.156




Figura 5. Histograma condicional - Vinho Tinto




Figura 7. Boxplots condicionais - Vinho Tinto




Figura 6. Histograma condicional - Vinho Branco




Figura 8. Boxplots condicionais - Vinho Branco

V. ANÁLISE BIVARIADA

A análise aprofundada e extensiva das relações pareadas cruzadas confirmou hipóteses previamente consolidadas e esperadas pelos fundamentos da química orgânica analítica. Atributos que possuem raízes biológicas correlacionadas demonstraram forte propensão ao alinhamento de forma retilínea ao longo dos gráficos de espalhamento bidimensional. A extração geométrica e quantitativa desses alinhamentos fornece alicerce inabalável para algoritmos de aprendizado que assumem dependência funcional.

O cruzamento das informações do mapa de calor denota que a densidade do líquido exibe uma correlação linear inversamente proporcional e consideravelmente robusta com o teor de álcool etílico precipitado. O álcool possui densidade física naturalmente inferior à da água pura. Portanto, fluidos com maior gradação alcoólica tendem, estruturalmente, a registrar um peso específico total menor. Outra correlação cruzada aguda, desta vez com alinhamento positivo e direto, manifestase de forma forte e incontestante entre as variáveis referentes ao

dióxido de enxofre livre e ao enxofre total, que logicamente compartilham propriedades genitoras.




Figura 9. Matriz de correlação




Figura 10. scatter plot

VI. ANÁLISE MULTIVARIADA

A. Projeção Espacial de Componentes Principais

A aplicação da rotação de bases ortogonais comprimiu os dados brutos. O processo partiu de doze eixos variáveis originais e convergiu o problema para duas dimensões matemáticas abstratas, devidamente otimizadas sob a ótica restrita da

variância absoluta. Essa compactação agressiva eliminou eixos fortemente correlacionados que contribuíam apenas com ruído analítico redundante para a segregação das classes principais.

A etapa imprescindível e precedente de padronização universal permitiu nivelar a escala de atuação dos doze fatores heterogêneos. Sem esse cuidado, variáveis associadas a grandezas de magnitude exorbitante manipulariam o ângulo rotacional autovetorial de maneira incorreta. A base ortogonal obtida garante que o novo espaço gerado possua componentes perpendiculares e totalmente descorrelacionados.

Conforme a vasta demarcação visual presente na figura, constata-se visualmente que as duas populações de vinhos se distanciam categoricamente uma da outra, deslizando paralelamente, de maneira prioritária, ao longo da pista orientada pelo primeiro componente principal. Esse primeiro eixo sintético atua como o alicerce discriminante e capta o contraste máximo absoluto da base.

A fronteira de separação aparente desenha um delineamento majoritariamente reto. Isso enfatiza o alto potencial classificador e discriminatório detectado nos testes monovariados anteriores deste relatório.




Figura 11. PCA

VII. CONSIDERAÇÕES FINAIS

A investigação estatística de natureza exploratória, retratada exhaustivamente neste relatório técnico, forneceu uma visão sobre a macroestrutura dos dados originários de colheitas portuguesas de vinho. A verificação empírica, inteiramente guiada por metodologias computacionais quantitativas clássicas e perfeitamente estabelecidas, confirmou concretamente a predominância sólida de padrões determinísticos associáveis às moléculas elementares.

O plano de fundo computacional e a lógica empregada na decomposição matricial criaram a prova da proeminência dos níveis voláteis de enxofre livre na detecção cega do fluido transparente, em oposição ao escuro avermelhado. A consolidação dessa documentação acadêmica e técnica operará firmemente como a ação inicial de experimentações futuras envolvendo modelagem matemática preditiva por intermédio de topologias de redes neurais, de grande dimensão sistêmica.

REFERÊNCIAS

- [1] <https://archive.ics.uci.edu/dataset/186/wine+quality>
- [2] An Introduction to Statistical Learning: With Applications in Python - Gareth M. James, Daniela Witten, Trevor Hastie, Robert Tibshirani
- [3] Applied Predictive Modeling - Max Kuhn, Kjell Johnson
- [4] Material didático fornecido pelo docente
- [5] <https://numpy.org/>
- [6] <https://matplotlib.org/stable/index.html>
- [7] <https://docs.scipy.org/doc/scipy/>
- [8] <https://pandas.pydata.org/docs/>